자연어 데이터 전처리

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

02

APPLICATION

ARTIFICIAL INTELLIGENCE

Notice

THINKING

생각해보기

✓ 자연어 데이터 전처리는 어떻게 할까요?

학습목표

GOALS

1 자연어 데이터 묶음 코퍼스에 대해 설명할 수 있다.

2 NLTK를 활용해 코퍼스에 대한 분석을 할 수 있다.

3 텍스트 수준 텍스트 전처리를 하는 방법을 설명할 수 있다.

4 단어 수준 텍스트 전처리를 하는 방법을 설명할 수 있다.

5 정규 표현식에 대해 이해하고 설명할 수 있다.

1 자연어 데이터

2 텍스트 데이터 전처리

3 실습

CONTENTS

학습내용

APPLICATION

01 자연어 데이터

01 코퍼스란?

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

코퍼스(corpus), 말뭉치

- 자연언어 연구를 위해 특정한 목적을 가지고 언어의 표본을 추출한 집합
- 컴퓨터에 저장된, 쓰이거나 말해진 자연어 자료 모음
- 둘 이상의 코퍼스가 존재하면 코포라(corpora)라고 부름

코퍼스 예시

```
'Austin/np-hl ,/,-hl Texas/np-hl \n--/-- Committee/nn approval/nn of/in Gov./nn-tl P
rice/np Daniel's/np$ ``/`` abandoned/vbn property/nn ''/'' act/nn seemed/vbd certai
n/jj Thursday/nr despite/in the/at adamant/jj protests/nns of/in Texas/np bankers/nn
s ./.\n\n\n\tDaniel/np personally/rb led/vbd the/at fight/nn for/in the/at measure/n
n ,/, which/wdt he/pps had/hvd watered/vbn down/rp considerably/rb since/in its/pp$
rejection/nn by/in two/cd previous/jj Legislatures/nns-tl ,/, in/in a/at public/jj h
earing/nn before/in the/at House/nn-tl Committee/nn-tl on/in-tl Revenue/nn-tl and/cc
-tl Taxation/nn-tl ./.\n\n\n\tUnder/in committee/nn rules/nns ,/, it/pps went/vbd au
tomatically/rb to/in a/at subcommittee/nn for/in one/cd week/nn ./.\nBut/cc question
s/nns with/in which/wdt committee/nn members/nns taunted/vbd bankers/nns appearing/v
bg as/cs witnesses/nns left/vbd little/ap doubt/nn that/cs they/ppss will/md recomme
nd/vb passage/nn of/in it/ppo ./.\n\n\n\tDaniel/np termed/vbd ``/`` extremely/...'
```


코퍼스의 도움으로 자연어에 대한 빈도 분포,
단어의 동시 발생 등과 같은 통계적인 분석이 가능하다.

다양한 자연어처리 과정에서 자연어 데이터에 대한
언어 규칙을 정의하고 이를 검증할 수 있다.

roul base

규칙 기반 시스템의 도움으로 언어 사용에 따라
각 언어에 대한 언어 규칙을 정의할 수 있다.

구성된 언어를 기준으로

03 코퍼스 수집

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

코퍼스 수집 방법

- 공개된 오픈소스 코퍼스 사용

NLTK, koLNTK : 파이썬에서 제공하는 툴킷

- 다양한 웹사이트에서 크롤링을 통한 자연어 데이터 수집

주의 : 저작권 문제, 트래픽 문제 등을 확인하며 크롤링 해야함

04 코퍼스 분석

1 음성데이터에서의 코퍼스 분석

- 각 데이터의 음성 이해에 대한 분석 및 대화 분석이 필요

2 텍스트데이터에서의 코퍼스 분석

- 일반적으로 코퍼스에 단어가 몇 개 나오는지, 코퍼스 내에 있는 특정 단어의 빈도수가 얼마인지를 분석
- 코퍼스에 노이즈가 있으면 노이즈를 제거

05 NLTK

NLTK(Natural Language Toolkit)

- Python 프로그래밍 언어로 작성된 영어의 자연어 처리를 위한 라이브러리 및 프로그램 모음
- 다양한 기능을 가지고 있으며 교육용 뿐만 아니라 실무 및 연구에서도 많이 사용
- 50종류 이상의 코포라와 어휘 자원을 가지고 있는 오픈소스 라이브러리

06 NLTK 내장 코포라

코포라 타입	설명	예시 코퍼스
아이솔레이트 코퍼스 (isolate corpus)	텍스트 또는 자연어의 모음	gutenberg 코퍼스 webtext 코퍼스
카테고리화 코퍼스 (Categorized corpus)	뉴스, 취미, 유머 등 다양한 타입의 부류로 그룹화된 텍스트 모음	brown 코퍼스
오버래핑 코퍼스 (Overlapping corpus)	분류됨 텍스트 모음이지만 카테고리가 서로 겹침	reuters 코퍼스
템포럴 코퍼스 (Temporal corpus)	일정 기간동안 자연어를 사용한 데이터 모음	Inaugural address 코퍼스

07 NLTK를 통해 코퍼스 다루어 보기

NLTK의 “brown” 코퍼스와 “gutenberg” 코퍼스 가져오기

```
In [1]:
1 import nltk
2 from nltk.corpus import brown as cb
3 from nltk.corpus import gutenberg as cg

In [2]:
1 nltk.download('brown')
2 nltk.download('gutenberg')

[nltk_data]
[nltk_data]
[nltk_data]
[nltk_data]
[nltk_data]
[nltk_data]

Out[2]: True
```

.fileids()를 통해 brown 코퍼스 파일 확인하기

```
In [3]: 1 cb.fileids()

Out[3]: ['ca01',
         'ca02',
         'ca03',
         'ca04',
         'ca05',
         'ca06',
         'ca07',
         'ca08',
         'ca09',
         'ca10',
         'ca11',
         'ca12',
         'ca13',
         'ca14',
         'ca15',
         'ca16',
         'ca17',
         'ca18',
         'ca19',
         'ca20',
```

07 NLTK를 통해 코퍼스 다루어 보기

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

.fileids()를 통해 brown 코퍼스 파일 확인하기

```
In [4]: 1 cg.fileids()

Out[4]: ['austen-emma.txt',
         'austen-persuasion.txt',
         'austen-sense.txt',
         'bible-kjv.txt',
         'blake-poems.txt',
         'bryant-stories.txt',
         'burgess-busterbrown.txt',
         'carroll-alice.txt',
         'chesterton-ball.txt',
         'chesterton-brown.txt',
         'chesterton-thursday.txt',
         'edgeworth-parents.txt',
         'melville-moby_dick.txt',
         'milton-paradise.txt',
         'shakespeare-caesar.txt',
         'shakespeare-hamlet.txt',
         'shakespeare-macbeth.txt',
         'whitman-leaves.txt']
```

.categories()를 통해 brown 코퍼스의 카테고리 나열하기

```
In [5]: 1 cb.categories()

Out[5]: ['adventure',
         'belles_lettres',
         'editorial',
         'fiction',
         'government',
         'hobbies',
         'humor',
         'learned',
         'lore',
         'mystery',
         'news',
         'religion',
         'reviews',
         'romance',
         'science_fiction']
```

07 NLTK를 통해 코퍼스 다루어 보기

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

.words()를 통해 brown 코퍼스의 전체 단어 나열하기

```
In [6]: 1 cb.words()[:20]

Out[6]: ['The',
         'Fulton',
         'County',
         'Grand',
         'Jury',
         'said',
         'Friday',
         'an',
         'investigation',
         'of',
         "Atlanta's",
         'recent',
         'primary',
         'election',
         'produced',
         '``',
         'no',
         'evidence',
         "''",
         'that']
```

20개만 보여달라고 정의함

.words()의 categories 인자로 코퍼스 내 지정한 category의 단어 나열하기

```
In [7]: 1 cb.words(categories='news')[10:30]
```

```
Out[7]: ["Atlanta's",
         'recent',
         'primary',
         'election',
         'produced',
         '``',
         'no',
         'evidence',
         "''",
         'that',
         'any',
         'irregularities',
         'took',
         'place',
         '.',
         'The',
         'jury',
         'further',
         'said',
         'in']
```

07 NLTK를 통해 코퍼스 다루어 보기

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

.Text()를 통해 특정 문서만 불러오기

```
In [8]: 1 raw_text = nltk.Text(cb.words('ca01'))
        2 raw_text
```

```
Out[8]: <Text: The Fulton County Grand Jury said Friday an...>
```

.concordance()를 통해 특정 단어가 들어간 문장 가져오기

```
In [9]: raw_text.concordance("The")
```

```
Displaying 25 of 155 matches:
 The Fulton County Grand Jury said Friday
 that any irregularities took place . The jury further said in term-end present
er said in term-end presentments that the City Executive Committee , which had
mittee , which had over-all charge of the election , `` deserves the praise and
 charge of the election , `` deserves the praise and thanks of the City of Atla
 `` deserves the praise and thanks of the City of Atlanta '' for the manner in
 thanks of the City of Atlanta '' for the manner in which the election was cond
of Atlanta '' for the manner in which the election was conducted . The Septembe
in which the election was conducted . The September-October term jury had been
s of possible `` irregularities '' in the hard-fought primary which was won by
ful of such reports was received '' , the jury said , `` considering the widesp
d '' , the jury said , `` considering the widespread interest in the election ,
onsidering the widespread interest in the election , the number of voters and t
widespread interest in the election , the number of voters and the size of this
e election , the number of voters and the size of this city '' . The jury said
voters and the size of this city '' . The jury said it did find that many of Ge
ave these laws studied and revised to the end of modernizing and improving them
f modernizing and improving them '' . The grand jury commented on a number of o
a number of other topics , among them the Atlanta and Fulton County purchasing
```

07 NLTK를 통해 코퍼스 다루어 보기

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

.raw_content()를 통해 가공 전 데이터 가져오기

```
In [10]: raw_content = cb.raw('ca02')
         raw_content
```

```
Out[10]: "Austin/np-hl ,/,-hl Texas/np-hl \n--/-- Committee/nn approval/nn of/in Gov./nn-tl Price/np Daniel's/np$ ``/`` abando
ned/vbn property/nn ''/'' act/nn seemed/vbd certain/jj Thursday/nr despite/in the/at adamant/jj protests/nns of/in Te
xas/np bankers/nns ./.\n\n\n\tDaniel/np personally/rb led/vbd the/at fight/nn for/in the/at measure/nn ,/, which/wdt
he/pps had/hvd watered/vbn down/rp considerably/rb since/in its/pp$ rejection/nn by/in two/cd previous/jj Legislature
s/nns-tl ,/, in/in a/at public/jj hearing/nn before/in the/at House/nn-tl Committee/nn-tl on/in-tl Revenue/nn-tl and/
cc-tl Taxation/nn-tl ./.\n\n\n\tUnder/in committee/nn rules/nns ,/, it/pps went/vbd automatically/rb to/in a/at subco
mmittee/nn for/in one/cd week/nn ./.\nBut/cc questions/nns with/in which/wdt committee/nn members/nns taunted/vbd ban
kers/nns appearing/vbg as/cs witnesses/nns left/vbd little/ap doubt/nn that/cs they/ppss will/md recommend/vb passag
e/nn of/in it/ppo ./.\n\n\n\tDaniel/np termed/vbd ``/`` extremely/rb conservative/jj ''/'' his/pp$ estimate/nn that/c
s it/pps would/md produce/vb 17/cd million/cd dollars/nns to/to help/vb erase/vb an/at anticipated/vbn deficit/nn of/
in 63/cd million/cd dollars/nns at/in the/at end/nn of/in the/at current/jj fiscal/jj year/nn next/ap Aug./np 31/cd
./.\n\n\n\tHe/pps told/vbd the/at committee/nn the/at measure/nn would/md merely/rb provide/vb means/nns of/in enforc
ing/vbg the/at escheat/nn law/nn which/wdt has/hvz been/ben on/in the/at books/nns ``/`` since/in Texas/np was/bedz
a/at republic/nn ''/'' ./.\nIt/pps permits/vbz the/at state/nn to/to take/vb over/rp bank/nn accounts/nns ,/, stocks/
nns and/cc other/ap personal/jj property/nn of/in persons/nns missing/vbg for/in seven/cd years/nns or/cc more/ap
./.\n\n\n\tThe/at bill/nn ,/, which/wdt Daniel/np said/vbd he/pps drafted/vbd personally/rb ,/, would/md force/vb ban
ks/nns ,/, insurance/nn firms/nns ,/, pipeline/nn companies/nns and/cc other/ap corporations/nns to/to report/vb suc
h/jj property/nn to/in the/at state/nn treasurer/nn ./.\nThe/at escheat/nn law/nn cannot/md* be/be enforced/vbn now/r
b because/cs it/pps is/bez almost/rb impossible/jj to/to locate/vb such/jj property/nn ,/, Daniel/np declared/vbd
./.\n\n\n\tDewey/np Lawrence/np ,/, a/at Tyler/np lawyer/nn representing/vbg the/at Texas/np-tl Bankers/nns-tl Associ
```

APPLICATION

02 텍스트 데이터 전처리

01 데이터 전처리란?

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

데이터 전처리

- 어떤 작업을 진행하기 이전에 주어진 데이터를 목적에 맞추어 변형 또는 가공하는 과정
- 자연어처리분야 뿐만 아니라 산업 전반적으로 매우 중요한 과정

> 이미 전처리된 데이터가 아닌
> 직접 크롤링하여 수집한 데이터 등의 경우
> 결과의 정확성을 위해 전처리는 필수적임

01 데이터 전처리란?

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

자연어처리에서 데이터 전처리 과정

토큰화

token : 문법에서 가장 작은 단위

정제

cleaning

정규화

등의 과정이 있음

데이터 토큰화(data tokenization)

주어진 코퍼스를 토큰이라는 단위로 나누는 과정

- 문장, 단어, 구두점 등 다양한 단위로 토큰을 설정할 수 있음
- nltk, OpenNLP, kss 등 토큰화를 수행하는 다양한 오픈소스 툴킷들이 존재함

텍스트 데이터에서 데이터는 단락 형태이므로 단락에서 문장을 뽑아내려면 문장 레벨로 토큰화하는 과정이 필요

```
In [1]:
1 text = """NLTK is a leading platform for building Python programs to work with human language data. It provides eas
2 text

Out[1]: 'NLTK is a leading platform for building Python programs to work with human language data. It provides easy-to-use in
terfaces to over 50 corpora and lexical resources such as WordNet, along with a suite of text processing libraries fo
r classification, tokenization, stemming, tagging, parsing, and semantic reasoning, wrappers for industrial-strength
NLP libraries, and an active discussion forum. Thanks to a hands-on guide introducing programming fundamentals alongs
ide topics in computational linguistics, plus comprehensive API documentation, NLTK is suitable for linguists, engine
ers, students, educators, researchers, and industry users alike. NLTK is available for Windows, Mac OS X, and Linux.
Best of all, NLTK is a free, open source, community-driven project.'
```

문단 > 문장 > 단어 > 형태소 > 음소

문단 > 문장

nltk의 sent_tokenize를 활용해 텍스트를 문장으로 토큰화하기

```
In [2]: 1 from nltk.tokenize import sent_tokenize

In [3]: 1 sent_tokenize(text)

Out[3]: ['NLTK is a leading platform for building Python programs to work with human language data.',
 'It provides easy-to-use interfaces to over 50 corpora and lexical resources such as WordNet, along with a suite of
text processing libraries for classification, tokenization, stemming, tagging, parsing, and semantic reasoning, wrapp
ers for industrial-strength NLP libraries, and an active discussion forum.',
 'Thanks to a hands-on guide introducing programming fundamentals alongside topics in computational linguistics, plus
comprehensive API documentation, NLTK is suitable for linguists, engineers, students, educators, researchers, and ind
ustry users alike.',
 'NLTK is available for Windows, Mac OS X, and Linux.',
 'Best of all, NLTK is a free, open source, community-driven project.']
```

03 NLTK를 활용한 문장 토큰화

문장 > 단어

단어 토큰화는 텍스트를 단어, 구, 의미 있는 문자열로 자르는 과정이다.

```
In [1]: 1 text = "If you really want to do something, you'll find a way. If you don't, you'll find an excuse."
        2 text

Out[1]: "If you really want to do something, you'll find a way. If you don't, you'll find an excuse."
```

< 가공 전 텍스트 >

nltk의 word_tokenize를 활용해 텍스트를 단어로 토큰화하기

```
In [2]: 1 from nltk.tokenize import word_tokenize
        2 word_tokenize(text)

Out[2]: ['If',
         'you',
         'really',
         'want',
         'to',
         'do',
         'something',
         ',',
         'you',
         "'ll",
         'find',
         'a',
         'way',
         '.',
         'If',
         'you',
         'do',
         "n't",
         ',',
         'you'
```

tokenize 되었다

If you really want to do something, you'll find a way.
If you don't, you'll find an excuse.

nltk의 WordPunctTokenizer를 활용한 토큰화

```
In [3]: 1 from nltk.tokenize import WordPunctTokenizer
        2 WordPunctTokenizer().tokenize(text)

Out[3]: ['If',
         'you',
         'really',
         'want',
         'to',
         'do',
         'something',
         ',',
         'you',
         "'",
         'll',
         'find',
         'a',
         'way',
         '.',
         'If',
         'you',
         'don',
         "'",
         't'
```

If you really want to do something, you'll find a way.
If you don't, you'll find an excuse.

1 상황과 목적에 맞는 토큰화 툴을 사용해야 한다.

- 앞의 예시와 같이, nltk의 word_tokenizer 의 경우 의미에 따라 단어를 분리하지만 WordPunctTokenizer의 경우 구두점을 기준으로 단어를 분리하므로 알맞은 토큰화 툴을 선택해야 함

  예시) don't → do / n't // don't → don / ' / t

04 토큰화에서 고려해야 할 점

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

2 구두점 또는 특수문자가 이미 포함된 단어의 경우

- She finally completed her Ph.D. degree. At that point, her boyfriend was eating hamburger which only costs $7.59 while reading J.K. Rowling's new book

- 위 문장의 경우 "Ph.D.", "$7.59", J.K. 의 경우 이미 온점이 포함되어 있기 때문에 Ph / D / 또는 $7 / 59 / 와 같이 분리하지 않도록 주의해야함

데이터 정제(data cleansing/cleaning)

Signal / Noise

Signal은 높이고
Noise 는 낮추는 과정

- 데이터에서 손상되거나 부정확한 부분을 감지하고 수정하는 과정
- 데이터의 불완전하거나 부정확하거나 관련이 없는 부분을 식별한 뒤에 해당 부분을 대체, 수정 또는 삭제하는 과정

05 데이터 정제와 데이터 정규화

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

데이터 정규화(data normalization)

- 텍스트 데이터에서 정규화는 표현 방법이 다른 단어들을 통합시켜 같은 단어로 통합시키는 과정

> **영어권에서 대소문자 통합과정은 일반적으로 소문자로 변환**

- 대소문자가 존재하는 영어권 언어의 경우 대소문자 통합과정은 서로 다른 단어의 개수를 줄일 수 있음

소문자로 통합하여 분석한다.

- 텍스트 내에서 'language'란 단어를 찾는 과정에서 문장 맨 앞의 'Language'의 L은 대문자이므로 찾지 못하는 상황을 방지함
- 사람 / 회사의 이름 등과 같이 반드시 대문자로 존재하는 단어를 고려하여 통합해야 함

06 대소문자 통합

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

파이썬 내장함수 .lower()를 활용해 소문자로 통합하기

In [1]:
```
def lowertext(text):
    return(text.lower())

text = "Happiness depends upon ourselves. Remember that happiness is a way of travel not a destination."

lowertext(text)
```

Out[1]: 'happiness depends upon ourselves. remember that happiness is a way of travel not a destination.'

어간 추출(Stemming)

접미사를 삭제하거나 대체하여 문장의 각 단어를 어근 형태로 변환하는 과정

- 접미사를 삭제 또는 대체하는 과정이므로 결과물이 사전에 존재하지 않는 단어일 수 있음
- 다양한 어간 추출 툴킷이 존재하지만 언어별로 잘 동작하지 않을 수 있음

가공 전 텍스트

```
In [1]:
1 text = "He always wanted to be a computer scientist. So he studies programming languages. Studying hard is only way
2 text

Out[1]: 'He always wanted to be a computer scientist. So he studies programming languages. Studying hard is only way to make
his dream come true'
```

nltk의 PorterStemmer를 활용해 어간 추출하기

```
In [2]: 1 from nltk.stem import PorterStemmer
        2 [PorterStemmer().stem(word) for word in text.split()]
```

```
'be',
'a',
'comput',
'scientist.',
'So',
'he',
'studi',
'program',
'languages.',
'studi',
'hard',
'is',
'onli',
'way',
'to',
'make',
'hi',
'dream',
'come',
'true']
```

He always wanted to be a computer scientist. So he studies programming languages. Studying hard is only way to make his dream come true

08 NLTK를 활용한 어간 추출

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

nltk의 LancasterStemmer를 활용해 어간 추출하기

```
In [3]: 1 from nltk.stem import LancasterStemmer
        2 [LancasterStemmer().stem(word) for word in text.split()]
```

```
'be',
'a',
'comput',
'scientist.',
'so',
'he',
'study',
'program',
'languages.',
'study',
'hard',
'is',
'on',
'way',
'to',
'mak',
'his',
'dream',
'com',
'tru']
```

He always wanted to be a computer scientist. So he studies programming languages. Studying hard is only way to make his dream come true

표제어 추출(Lemmatizing)

정확하게 의도된 품사(POS, part-of-speech)와 문장에 있는 단어의 의미를 식별하는 과정

- 활용 어미를 없애고 단어를 사전이나 어휘에 존재하는 기본형으로 변환
- Wordnet과 같은 태그가 있는 사전을 사용해 가공 전 텍스트를 표제어(lemma)로 변환

품사 태그(POS tagging)

- 단어는 형태가 같아도 품사에 따라 의미가 크게 달라질 수 있음
- 정의와 문맥에 따라 텍스트의 특정 부분에 해당하는 단어를 마크 업하는 과정임

In [2]:
```
from nltk.tokenize import word_tokenize
from nltk.tag import pos_tag

text = "She finally completed Ph.D. degree."

word_token = word_tokenize(text)
print(pos_tag(word_token))
```

```
[('She', 'PRP'), ('finally', 'RB'), ('completed', 'VBD'), ('Ph.D.', 'NNP'), ('degree', 'NN'), ('.', '.')]
```

품사를 지정하여 표제어 추출하기

```
In [7]: WordNetLemmatizer().lemmatize('better', pos='a')
Out[7]: 'good'

In [8]: WordNetLemmatizer().lemmatize('funnier',pos='a')
Out[8]: 'funny'

In [9]: WordNetLemmatizer().lemmatize('meeting',pos='n')
Out[9]: 'meeting'

In [10]: WordNetLemmatizer().lemmatize('meeting',pos='v')
Out[10]: 'meet'

In [11]: WordNetLemmatizer().lemmatize('expected',pos='v')
Out[11]: 'expect'
```

11 NLTK를 활용한 표제어 추출

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

```
In [1]: text = "He always wanted to be a computer scientist. So he studies programming languages. Studying hard is only way
        text

Out[1]: 'He always wanted to be a computer scientist. So he studies programming languages. Studying hard is only way to make
        his dream come true'
```

< 가공 전 텍스트 >

nltk의 WordNetLemmatizer를 활용해 표제어 추출하기

```
In [5]: 1 from nltk.stem import WordNetLemmatizer
        2 [WordNetLemmatizer().lemmatize(word) for word in text.split()]

Out[5]: ['He',
         'always',
         'wanted',
         'to',
         'be',
         'a',
         'computer',
         'scientist.',
         'So',
         'he',
         'study',
         'programming',
         'languages.',
         'Studying',
         'hard',
         'is',
         'only',
         'way',
         'to',
         'make'
```

He always wanted to be a computer scientist. So he studies programming languages. Studying hard is only way to make his dream come true

명사로 바뀌어 있다.:
Studying => study

11 NLTK를 활용한 표제어 추출

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

품사를 지정하여 표제어 추출하기

```
In [6]: 1 from nltk.stem import WordNetLemmatizer
        2 [WordNetLemmatizer().lemmatize(word, 'v') for word in text.split()]

Out[6]: ['He',
         'always',
         'want',
         'to',
         'be',
         'a',
         'computer',
         'scientist.',
         'So',
         'he',
         'study',
         'program',
         'languages.',
         'Studying',
         'hard',
         'be',
         'only',
         'way',
         'to',
         'make'
```

He always wanted to be a computer scientist. So he studies programming languages. Studying hard is only way to make his dream come true

불용어(stopwords)

- 문장 형성에 있어서 중요한 구문론적 가치를 지니고 있지만 무시할 수 있거나 최소한의 의미적 가치를 지닌 단어

nltk의 불용어 리스트

'i', 'me', 'my', 'myself', 'you', "you're", 'am', 'is', 'are', 'was', 'were', 'be' 등

In [ ]:

```
1 import nltk
2 from nltk.corpus import stopwords
3 nltk.download('stopwords')
4
5 stopwordslist = stopwords.words('english')
6 stopwordslist
```

APPLICATION

03 실습

SUMMARY

학습정리

- 자연어 데이터 묶음 코퍼스
- NLTK를 활용한 코퍼스에 대한 분석
- 텍스트 수준 텍스트 전처리
- 단어 수준 텍스트 전처리
- 정규 표현식

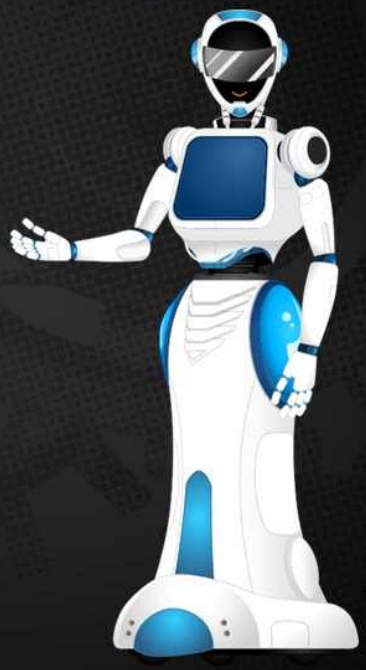

DEEP LEARNING AND NATURAL LANGUAGE PROCESSING

EXPANSION

확장하기

1. 코퍼스로 우리는 무엇을 할 수 있을까요?
2. NLTK란 무엇일까요?
3. 데이터의 토큰화는 무엇인가요?
4. NLTK에서 어간을 추출하는 방법에는 어떤 것들이 있을까요?
5. 불용어는 무엇인가요?

참고 문헌

REFERENCE

◆ 참고 논문
- Young, T, Hazarika, D., Poria, S., & Cambria, E. (2017). Recent Trends in Deep Learning Based Natural Language Processing. arXov preprint arXiv:1708.02709

◆ 참고 사이트
- 용어들에 대한 정의: https://ko.wikipedia.org/wiki.
- 퍼블릭에이아이(www.public.co.kr)

◆ 참고 서적
- 김기현, 『김기현의 자연어 처리 딥러닝 캠프 파이토치 편』, 한빛미디어, 2019
- 잘라지 트하나키, 『파이썬 자연어 처리의 이론과 실제』, 에이콘, 2017

서체 출처 : 에스코어드림체-㈜에스코어, 나눔글꼴체-㈜네이버