

## **Notice**

이 교육과정은 교육부 '성인학습자 역량 강화 교육콘텐츠 개발 ' 사업의 일환으로써 교육부로부터 예산을 지원 받아 고려사이버대학교가 개발하여 운영하고 있습니다. 제공하는 강좌 및 학습에 따르는 모든 산출물의 적작권은 교육부, 한국교육학술정보원, 한국원격대학협의외와 고려사이버대학교가 공동 소유하고 있습니다.



# 학습목표

**GOALS** 

BPTT의 문제점에 대해 설명할 수 있다.

Truncated BPTT 모델에 대해 설명할 수 있다.

LSTM의 기본 구조에 대해 배우고 설명할 수 있다.

Enter

4 LSTM의 작동 원리와 다양한 변형에 대해 설명할 수 있다.




BPTT의 문제점



01 데이터셋 확인하기

Anthony intelligence (All refers

#### Toy 데이터셋 생성 및 시각화 코드



출처: 퍼블릭에이아이(www.publicai.co.kr)

# 02 Orthogonal Initialization

#### BPTT는 아래 수식과 같이 전파됨

 $tanh'(a^{(t)})를 1이라 가정하면,$ 

 $\frac{\partial L}{\partial h} = \frac{\partial L}{\partial h^{(t)}} = \frac{\partial a^{(t)}}{\partial h^{(t-1)}} = \frac{\partial L}{\partial h^{(t)}} tanh'(a^{(t)}) W_{hh}$ 

$$\frac{\partial L}{\partial h_{(t-1)}} \approx \; \frac{\partial L}{\partial h^{(t)}} W_{hh}$$

$$rac{\partial L}{\partial h_{(t-n)}} pprox rac{\partial L}{\partial h^{(t)}} (W_{hh})^n$$

- 위 수식과 같이 N번의 Time step을 진행하게 되면, whit가 N번 반복하는 행렬곱 연산이 진행됨
- 초기 whh의 값에 따라 오차가 매우 크게 증폭될 수도 있고, 매우 적게 수렴될 수도 있음

ritin in intelligence (All refer

#### 예시 가중치 행렬

# 02 Orthogonal Initialization

Artificial Intelligence (All refer

#### 가중치 행렬의 크기 : 보통 L2 norm으로 계산


```
In [5]: 1 np.sqrt(np.sum(weight**2))
Out[5]: 10.956754373466538
    위의 수식을 Numpy에서는 아래와 같이 메소드를 제공합니다.
In [6]: 1 np.linalg.norm(weight)
Out[6]: 10.956754373466538
```

PLEARNING AND NATURAL LANGUAGE PROCESSING

#### 연산이 거듭됨에 따른 가중치의 변화

```
w = weight.copy()
w_norms = []
for i in range(5):
    w = np.matmul(weight,w)
    w_norms.append(np.linalg.norm(w))


plt.plot(w_norms)
plt.show()
```



```
weight = np.random.normal(0,0.1,100).reshape(10,10)

w = weight.copy()
w_norms = []
for i in range(5):
    w = np.matmul(weight,w)
    w_norms.append(np.linalg.norm(w))

plt.plot(w_norms)
plt.show()
```



# 02 Orthogonal Initialization

Artificial (stalligance (Al) return

#### Orthogonal Initialization

SVD(SinIge Value Decomposition)를 통해 가중치 행렬의 각 행이
 모두 수직이 되도록 만드는 방법




• U matrix가 바로 직교 행렬

U matrix의 각 행은 Eigen Vector로 구성되어 있음


# DITERINATING AND NATURAL CANGULAGE RECORDS NO

#### Orthogonal Initialization 수행 시 가중치 추세



# 03 Gradient Clipping

## Gradient Clipping이란?



Artificial Intelligence (All refere

# EFICATIONS AND NATURAL LANGUAGE PERCESSING

#### Gradient exploding 시의 문제 재현 - 모델 구성하기

# 03 Gradient Clipping

Artificial Intelligence (All refer

#### Gradient exploding 시의 문제 재현 - 모델 학습하기

Please use Model.fit, which supports generators.

===] - 3s 34ms/step - loss: nan

#### Gradient Clipping

Gradient의 최대 크기를 제한하고, 만약 최대치를 넘게 되면
 Gradient의 크기를 재조정하는 방법

$$\hat{g} = \frac{\partial \varepsilon}{\partial \theta}$$

$$\begin{cases} \hat{g} \leftarrow \frac{threshold}{||\hat{g}||} \hat{g}, & \text{if } |\hat{g}| \ge threshold \\ \hat{g} \leftarrow \hat{g}, & \text{if } |\hat{g}| < threshold \end{cases}$$

# 03 Gradient Clipping

Artificial Intelligence (All refere

#### Gradient Clipping - 모델 구성하기

```
In [14]:
         1 K.clear_session()
          2 n_inputs = 1
           3 n_steps = 50
           n_neurons = 200
           5 n_outputs = n_inputs
           7 inputs = Input(shape=(n_steps,n_inputs))
           8 rec_init = tf.keras.initializers.RandomNormal(0,1.)
           9 hidden = SimpleRNN(n_neurons,
                               recurrent initializer=rec_init)(inputs)
         11 output = Dense(1)(hidden)
         13 model = Model(inputs,output)
         15 # Optimizer에 clipnorm=0.1을 지정하는 것으로
         16 # gradient clipping 적용가능
         17 model.compile(loss=tf.losses.mean_squared_error,
                          optimizer=Adam(lr=le-4, clipnorm=.1))
```

# 03 Gradient Clipping

#### Gradient Clipping - 모델 학습하기

```
In [15]:
             batch_size = 16
             train_gen = timeseries_generator(n_steps, batch_size)
             hist = model.fit_generator(train_gen,
                                          steps_per_epoch=100,
epochs=10)
         Epoch 1/10
         100/100 [=
                                             =====] - 3s 35ms/step - loss: 2.4639
          Epoch 2/10
         100/100 [==
                                                     - 3s 34ms/step - loss: 2.2776
         Epoch 3/10
          100/100 [=
                                                       3s 33ms/step - loss: 2.1678
         Epoch 4/10
100/100 [==
                                                     - 3s 35ms/step - loss: 2.1198
          Epoch 5/10
         100/100 [==
                                                     - 3s 34ms/step - loss: 2.0176
         Epoch 6/10
         100/100 [=
                                                       3s 33ms/step - loss: 1.9450
         Epoch 7/10
          100/100 [==
                                                     - 4s 35ms/step - loss: 1.8178
          Epoch 8/10
         100/100 [==
                                                     - 3s 33ms/step - loss: 1.7278
         Epoch 9/10
         100/100 [=
                                                   ] - 3s 33ms/step - loss: 1.5797
         Epoch 10/10
          100/100 [==:
                                              ====] - 4s 35ms/step - loss: 1.6647
```


# 04 Truncated BPTT

Artificial Intelligence (All refer

#### Truncated BPTT

- 학습 시 Error의 전파를 특정 구간별로 자르는 방법
- 본질적으로 BPTT 과정에서 문제가 발생되는 부분은 긴 시계열 데이터를 다루는 경우
- 긴 시계열 데이터의 경우 Gradient를 계산하기 위해 각 Time step 별로
   값을 저장하기 때문에 메모리 이슈와 Gradient 이슈가 존재


#### Truncated BPTT



# 04 Keras로 Truncated BPTT 구현하기

Artificial (stalligance (Al) return

## 데이터 확인하기



#### 모델 구성하기

04 Keras로 Truncated BPTT 구현하기

rtiturer jistelligenne (All refere

#### Stateful 을 위한 Generator 구성하기

```
In [19]: 1 total_ts = []
2 final_ys = []
3 for _ in range(batch_size):
    timeseries, y = generate_timeseries(n_steps=1000)
    total_ts.append(timeseries)
6     final_ys.append(timeseries)
7     total_ts = mp.stack(total_ts)
9     final_ys = mp.stack(total_ts)
9     final_ys = mp.stack(final_ys)[:,np.newaxis]

In [20]: 1 print("total_ts2 % ! ",total_ts.shape)
2 print("final_ys2 % ! ",total_ts.shape)
    total_ts2 % ! (16, 1000)
    final_ys2 % ! (16, 1)

1 train_ys = mp.concatenate((train_xs[:,11,0], final_ys],axis=1)
2 print("train_ys2 % ! ", train_ys.shape)

1 train_ys2 % ! (16, 5)

1 train_ys = train_ys.transpose(1,0,2)[...,np.newaxis]
2 train_ys = train_ys.transpose(1,0,2)[...,np.newaxis]
3 print("train_ys2 % ! ", train_ys.shape)

1 train_ys2 % ! ", train_ys.shape)

1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
1 train_ys2 % ! ", train_ys.shape)
```

#### Stateful 을 위한 Generator 구성하기

```
In [24]: 1 def generate_stateful_sequences(batch_size=16,
                                                   truncated steps=50,
                                                   n_steps=1000):
                   total ts = []
                   final_ys = []
for _ in range(batch_size):
                        timeseries, y = generate timeseries(n steps)
                        total_ts.append(timeseries)
                        final_ys.append(y)
                   total_ts = np.stack(total_ts)
final_ys = np.stack(final_ys)[:,np.newaxis]
           13
                   train_xs = (total_ts.reshape((batch_size,-1,truncated_steps)))
                   train_ys = np.concatenate([train_xs[:,1:,0], final_ys],axis=1)
           17
                   train_xs = train_xs.transpose(1,0,2)[...,np.newaxis]
                   train_ys = train_ys.transpose(1,0)[...,np.newaxis]
return train_xs, train_ys
           18
           19
```

04 Keras로 Truncated BPTT 구현하기

Artificial (stalligance (Al) return

#### Truncated BPTT 적용하기

02

LSTM이란?




01 LSTM

Artifusia: proviligance (All refer

# **LSTM(Long Short-Term Memory)**

- °RNN의 hidden state에 cell-state를 추가한 구조
- □ Input과 output 사이에 긴 time step이 존재할 때 학습에 어려움이 있는 BPTT의 이슈를 개선하고자 고안된 모델
  - RNN의 Cell을 개선하여 해결하고자 함

#### 기존의 RNN Cell



출처: 퍼블릭에이아이(www.publicai.co,kr)


#### **02** LSTM의 기본 구조

출처: http://colah.github.io/posts/2015-08-Understanding-LSTMs/




rtifusia intelligance (Al) refere






#### Forget Gate



출처: http://colah.github.io/posts/2015-08-Understanding-LSTMs/

## 04 LSTM 수식 단순화하기

Anthony intelligence (All refers





 $x_t \cdot W_x^{(f)} + h_t \cdot W_h^{(f)} + b^{(f)}$ 

 $x_t \cdot W_x^{(o)} + h_t \cdot W_h^{(o)} + b^{(o)}$ 

 $x_t \cdot W_x^{(i)} + h_t \cdot W_h^{(i)} + b^{(i)}$ 

 $= x_t \cdot W_x + h_t \cdot W_h + b$ 

$$x_t \cdot W_x^{(u)} + h_t \cdot W_h^{(u)} + b^{(u)}$$
• 이 식을 정리하면 아래처럼 구현이 됩니다. 
$$x_t \cdot [W_x^{(f)}, W_x^{(o)}, W_x^{(i)}, W_x^{(u)}] + h_t \cdot [W_h^{(f)}, W_h^{(o)}, W_h^{(i)}, W_h^{(u)}] + [b^{(f)}, b^{(o)}, b^{(i)}, b^{(u)}]$$

```
1 class LSTMCell(Layer):
In [3]:
                 def __init__(self, n_units, **kwargs):
    self.n_units = n_units
    self.state_size = (n_units, n_units)
    super(LSTMCell, self).__init__(**kwargs)
                  def build(self, input_shape):
    self.wx = self.add_weight("weight_x",
                                                     shape=(input_shape[-1],self.n_units*4),
          10
                                                     initializer='glorot_uniform')
                      11
          13
                                                     initializer='orthogonal')
                      14
          15
                                                    initializer='zeros')
          17
                      super(LSTMCell, self).build(input_shape)
          18
          19
                  def call(self, x, states):
                      h, c = states
# 행렬곱 연산
          21
22
                      z = tf.dot(x, self.wx) + tf.dot(h, self.wh) + self.b
                       # forget에 관련된 처리들
          25
                      forget_fate = tf.sigmoid(z[:,:self.n_units])
# update에 관련된 처리들
          26
                       input_gate = tf.sigmoid(z[:,self.n_units:self.n_units*2])
                      update = tf.tanh(z[:,self.n_units*2:self.n_units*3])
new_c = forget_gate * c + update * input_gate
# output에 관련된 처리들
          29
          30
                       output_gate = tf.sigmoid(z[:,self.n_units*3:])
          32
                       new_h = output_gate * tf.tanh(new_c)
          33
          34
                       return output, [new h, new c]
```

## 06 Keras를 활용한 LSTM

```
In [4]:
          1 from tensorflow.keras.layers import LSTMCell, RNN, Input, Dense
           from tensorflow.keras.models import Model
            K.clear_session()
          5 n_steps = 30
6 n_inputs = 50
          7 n_hiddens = 100
          8 n_outputs = 3
         10 inputs = Input(shape=(n_steps,n_inputs))
         hidden = RNN(LSTMCell(n_hiddens))(inputs)
         12 output = Dense(n_outputs,activation='softmax')(hidden)
         14 model = Model(inputs,output)
         16 model.summary()
```

Model: "functional\_1"

Layer (type)	Output Shape	Param #
input_1 (InputLayer)	[(None, 30, 50)]	0
rnn (RNN)	(None, 100)	60400
dense (Dense)	(None, 3)	303
Total params: 60,703		
Trainable params: 60,703		
Non-trainable params: 0		

## In [5]: 1 from tensorflow.keras.layers import LSTM K.clear\_session() n\_steps = 30 n\_inputs = 50 n\_hiddens = 100 n\_outputs = 3 9 inputs = Input(shape=(n\_steps,n\_inputs)) 10 hidden = LSTM(n\_hiddens)(inputs) 11 output = Dense(n\_outputs,activation='softmax')(hidden) 13 model = Model(inputs,output) 15 model.summary()


Model: "functional\_1"


Layer (type)	Output Shape	Param #
input_1 (InputLayer)	[(None, 30, 50)]	0
lstm (LSTM)	(None, 100)	60400
dense (Dense)	(None, 3)	303

Trainable params: 60,703 Non-trainable params: 0

#### **07** LSTM의 순전파







출처: http://colah.github.io/posts/2015-08-Understanding-LSTMs/





#### RNN에 비해 훨씬 더 많은 Weights를 가지고 있음

→ 3개의 gate와 하나의 update로 인해, 총 4배의 weight

추가적으로 3번의 sigmoid 연산과 1번의 tanh 연산이 더해지기 때문에 Cell에서 처리하는데에 좀더 많은시간을 필요로함

APPLICATION

03

실습



#### SUMMARY

# 학습정리

- ♦ BPTT의 문제를 해결하기 위한 Orthogonal Initialization
- ◆ Recurrent weight의 초기화 방법 Gradient Clipping
- ◆ Error의 전파를 특정 구간별로 자르는 Truncated BPTT
- LSTM (Long Short-Term Memory)

# 확장하기

- 1. Orthogonal Initialization은 무엇이고 다른 초기화 방법에는 어떤 것들이 있을까요?
- 2. Gradient Clipping은 무엇 이고 어떤 원리로 동작할까요?
- 3. Truncated BPTT는 어떤 경우에 주로 사용하고 어떤 이슈가 존재할까요?
- 4. LSTM은 기존의 RNN Cell과 어떻게 다를까요?
- 5. LSTM의 메모리와 연산량에는 어떤 특징이 있을까요?

# **참고** 문헌

REFERENCE

- ♦ 참고 사이트
  - 용어들에 대한 정의 : https://ko.wikipedia.org/wiki.
  - Understandig LSTM Networks: http://colah.github.io/posts/2015-08-Understanding-LSTMs/
  - 퍼블릭에이아이(www.publicai.co.kr)
- ♦ 참고 서적
  - 사이토 고키, 「밑바닥 부터 시작하는 딥러닝 2」, 한빛미디어, 2019